

## 次世代シーケンサの活用法

神沼英里<sup>1</sup>,望月孝子<sup>1</sup>,児玉悠一<sup>1</sup>,猿橋智<sup>1</sup>,菅原秀明<sup>1</sup>, 大久保公策<sup>1,2</sup>, 高木利久<sup>1,2</sup>, 中村保一<sup>1</sup>

1 国立遺伝学研究所 生命情報・DDBJ研究センター 2 ライフサイエンス統合データベースセンター

AJACS湘南3 2010年6月4日(金)14:20-15:20 日本大学生物資源科学部 2号館231教室



## 目次

#### 次世代シーケンサの活用法

- ①次世代シーケンサの特徴・原理
  - •新旧ゲノム解析技術の比較
  - •次世代シークエンサーの特徴
  - •次世代シークエンサーの原理
- ②次世代シーケンサの活用事例
  - •解析事例
- ③次世代シークエンサ・データの登録・解析
  - DDBJのアーカイブ・データベース
  - DDBJのクラウド型解析パイプライン
- ④DDBJクラウド型解析パイプラインのデモ

## ③次世代シークエンサ・データの 登録・解析



## DDBJにおける塩基配列データの登録 →論文用アクセッション番号発行

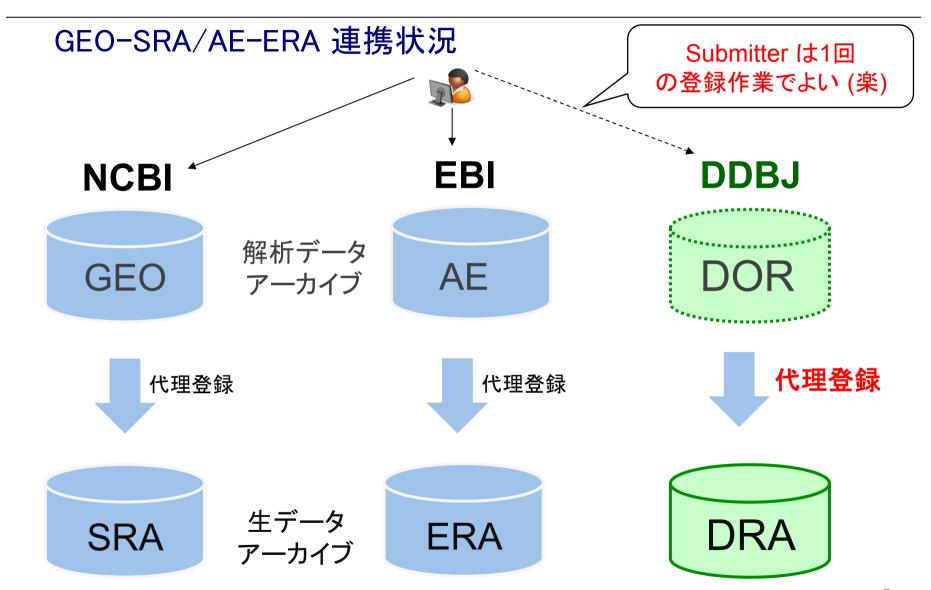
定量データ 配列データ **DDBJ Omics DDBJ** 解析データ ARchive(DOR) の登録 国際協力 国際協力 **NCBI** FBI **GEO** ArrayExpress (EMBL-Bank) (GenBank) 生データ DTA DRA の登録 (DDBJ Trace Archive) (DDBJ Read Archive) キャピラリ 次世代

シークエンサ

シークエンサ

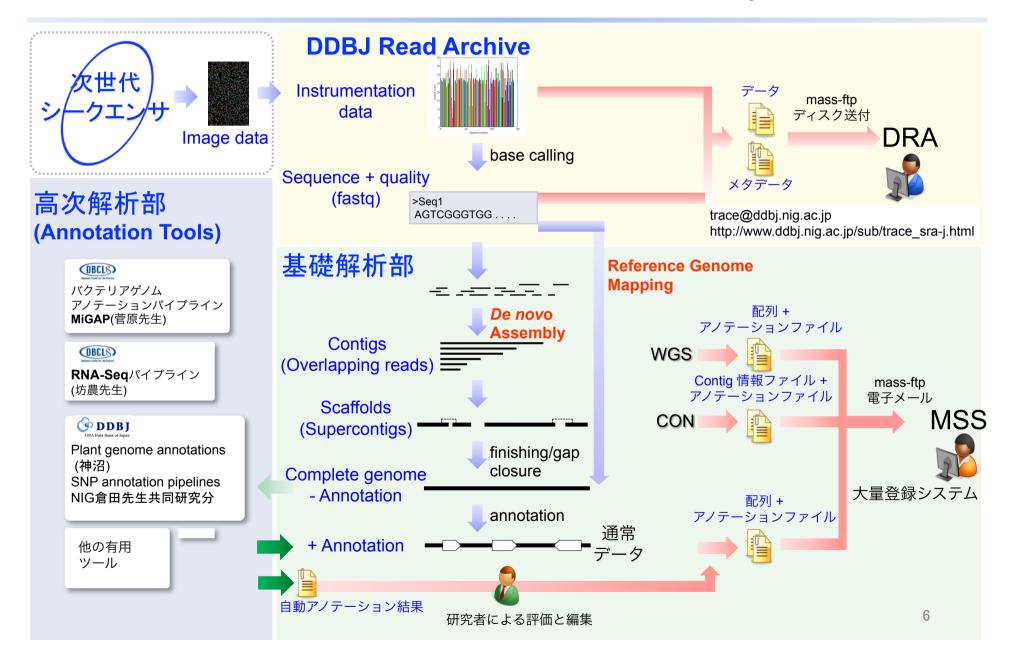


## DDBJ Omics Archiveから DRAへの代理登録





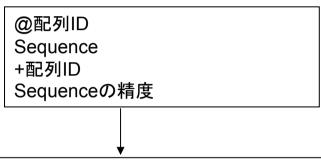
## **DDBJ Read Annotation Pipeline**





## FASTQ ファイルと形式とBase Call精度

#### FASTQ format



@ID49\_20708\_20H04AAXX\_R1:7:300:39:401 GTCTCGACCAGCCTCGACAACCTC ... +ID49\_20708\_20H04AAXX\_R1:7:300:39:401 hhUhhhhhYhhhhhhhhhehcaa`BSKhh\XH ...

Q score (Phred)	ASCII dec	ASCII Glyph
0	64	<b>@</b>
:	:	
40	104	h

#### Q-score (evaluation measure of base calls)

Phred quality scores are logarithmically linked to error probabilities

Quality of Phred Score	Probability of incorrect base call	Base call accuracy		
10	1 in 10	90 %		
20	1 in 100	99 %		
30	1 in 1000	99.9 %		
40	1 in 10000	99.99 %		
50	1 in 100000	99.999 %		

Ref. http://en.wikipedia.org/wiki/FASTQ format

$$Q_{\text{phred}} = -10 \, \log_{10} p \qquad \qquad Q_{\text{solexa}} = -10 \, \log_{10} \frac{p}{1-p}$$

Solexa現バージョン (illumina 1.3 format)

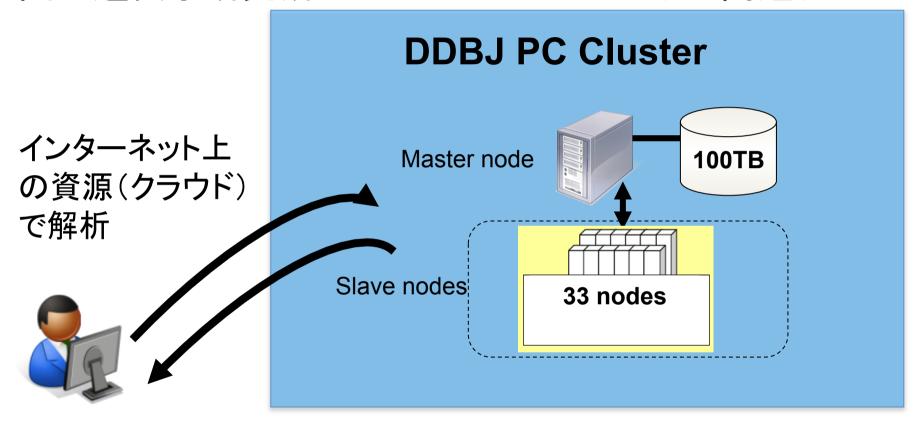
通常=Q20以上しか使わない ラボによりQ15以上使う所もあり。



#### パイプラインの特徴(1)

## クラウド型の解析システム

## 国立遺伝学研究所のスーパーコンピュータで高速化



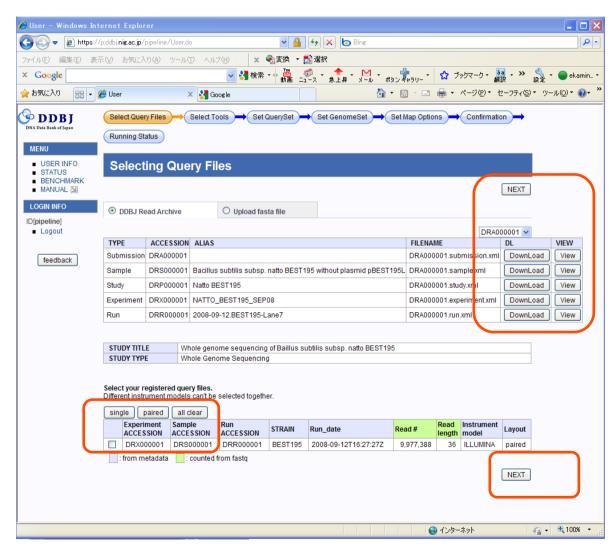
	CPU	Memory	Time	Maximum Job#
Computer nodes	2*3.16GHz	4GB	168H	42



#### パイプラインの特徴②

## 実験研究者が自分1人で解析可能

## ボタン操作、テキスト入力のみで解析結果取得

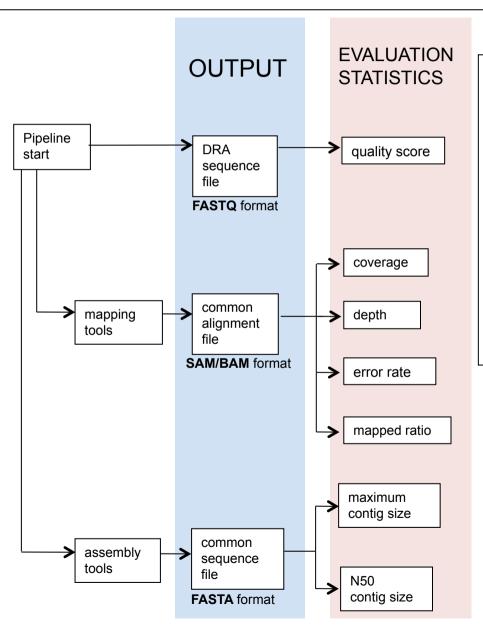


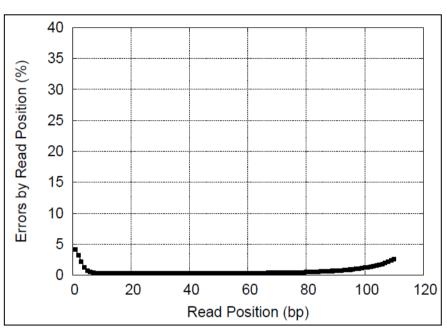
## プログラミング しなくても解析可



## → DDBJ パイプラインの特徴③

## DNA Data Bank of Japan 基本統計量(Quality Score/Coverage等)を自動計算



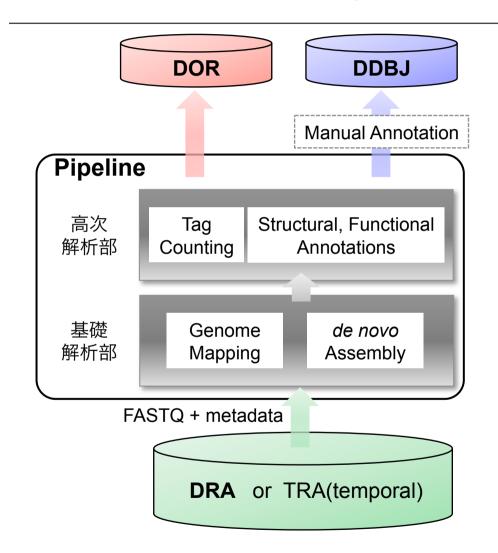


論文用の基本統計量、 図を生成

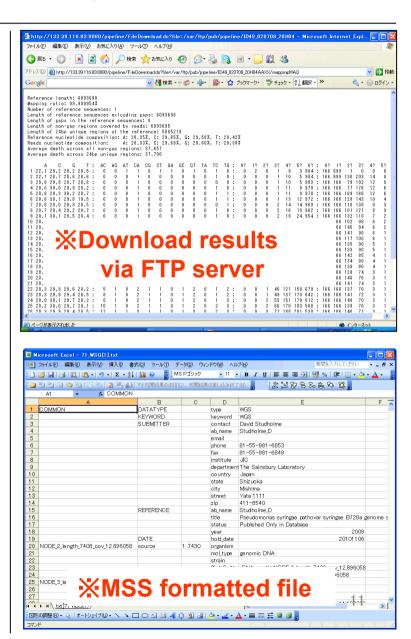


#### DDBJ パイプラインの特徴④

## < 配列登録支援>DDBJ登録ファイル自動生成



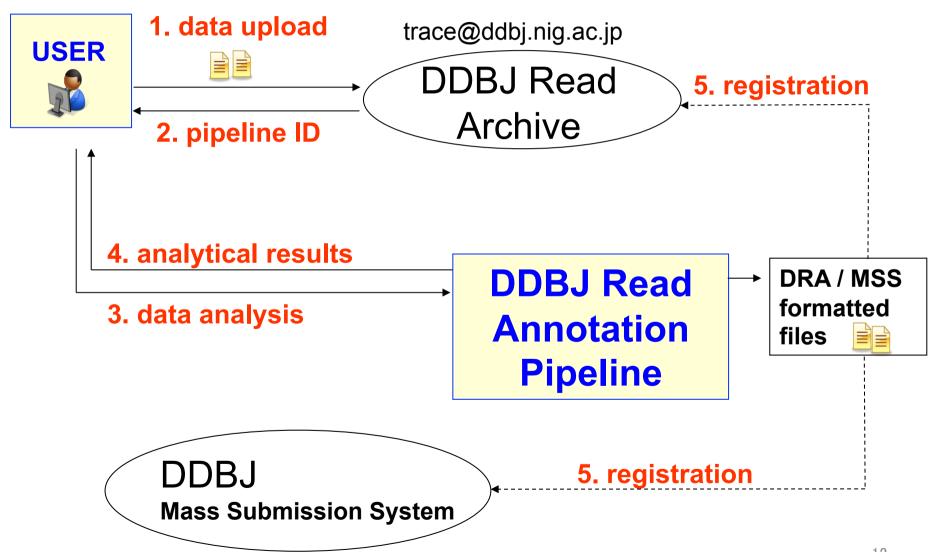
解析配列の登録手間を短縮





## 解析パイプラインの利用には、まず

<u>trace@ddbj.nig.ac.jp</u>へ連絡

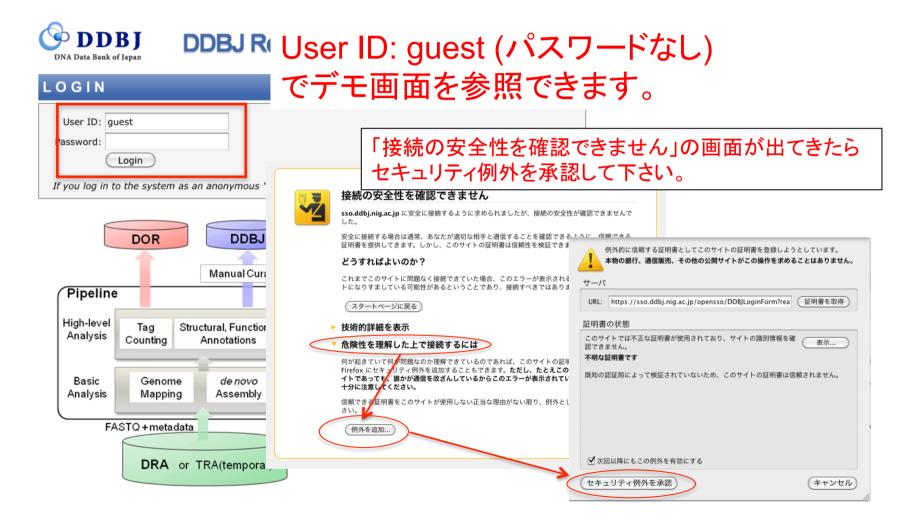


# ④DDBJクラウド型解析パイプラインのデモ



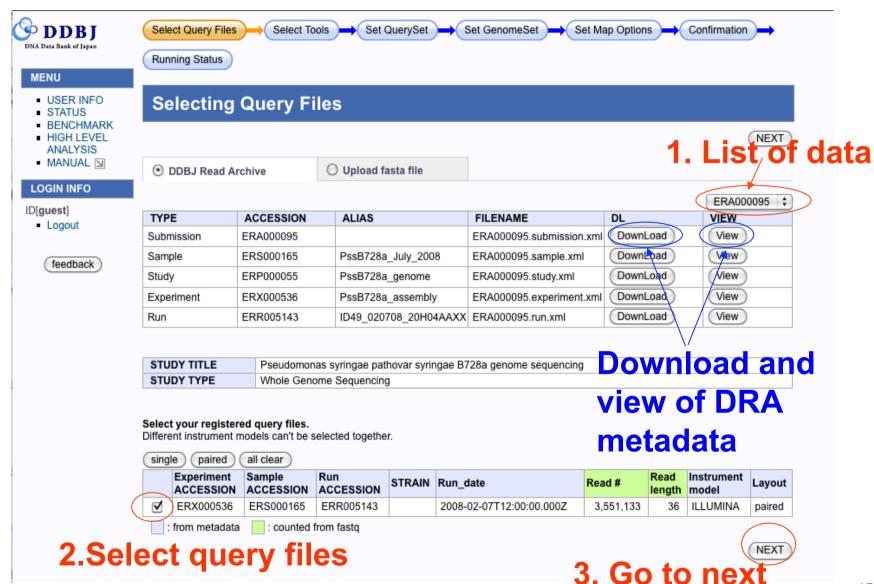
## 解析パイプライン DDBJ Read Annotation Pipeline

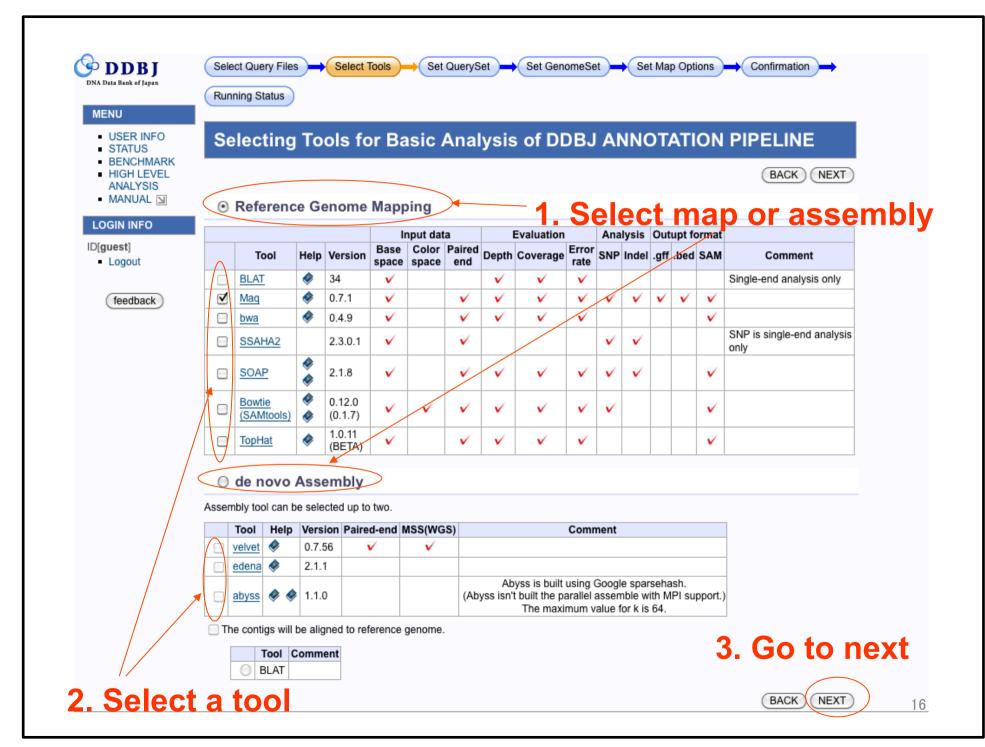
解析パイプライン https://p.ddbj.nig.ac.jp/

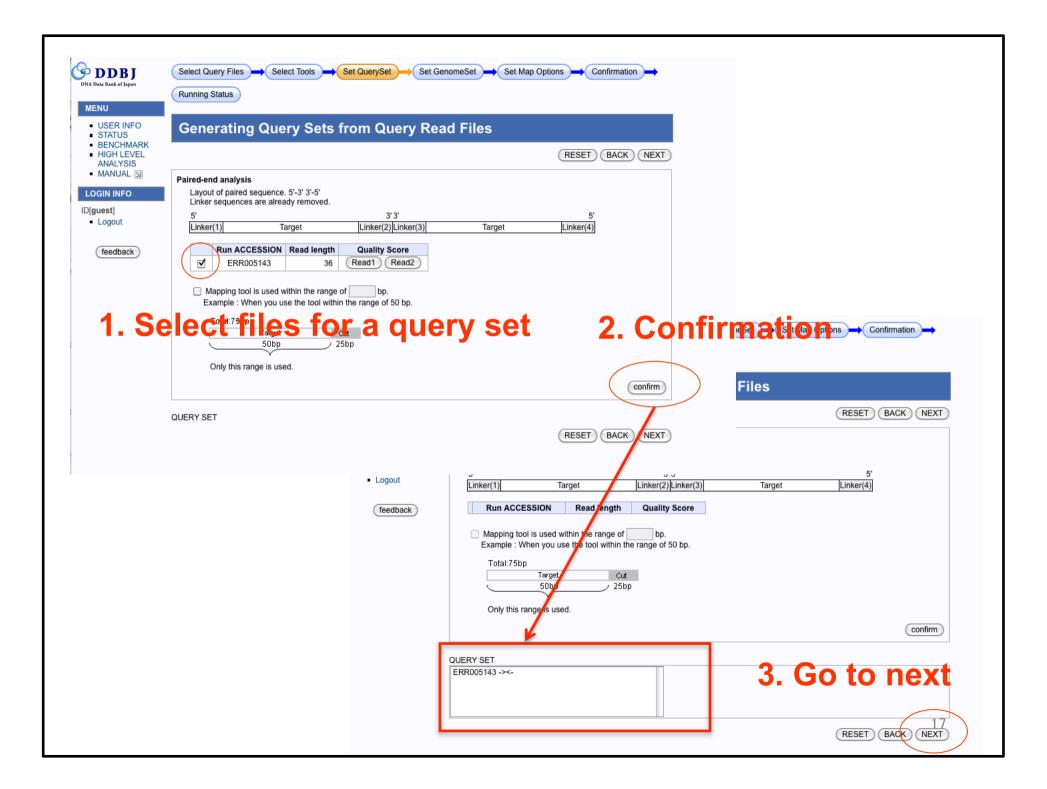


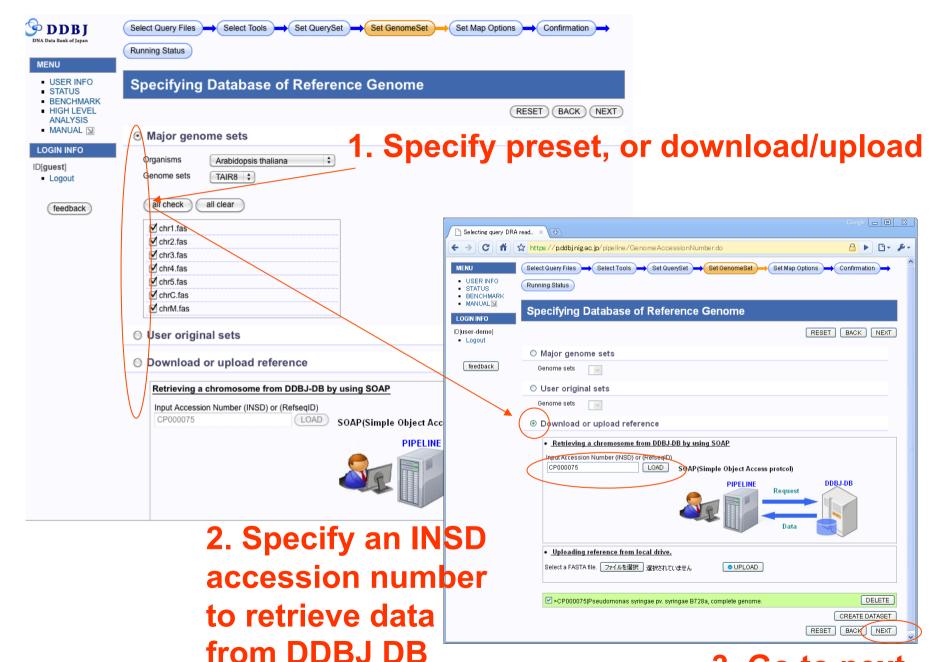


## クエリ用FASTQ形式READファイルの選択



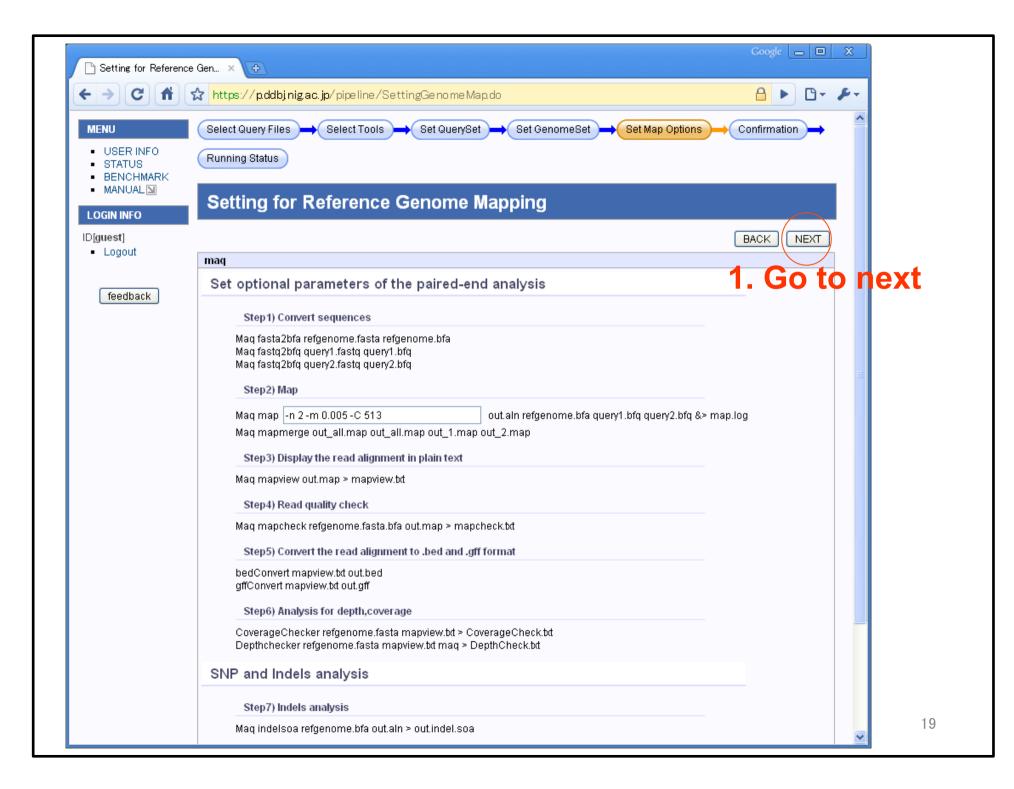


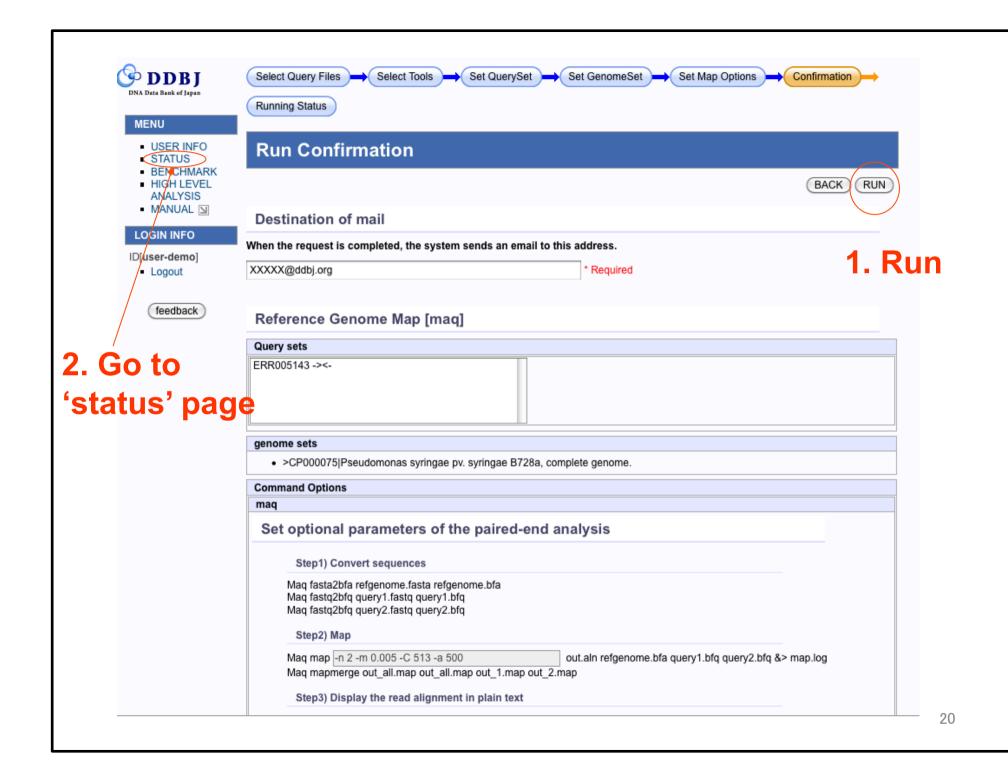


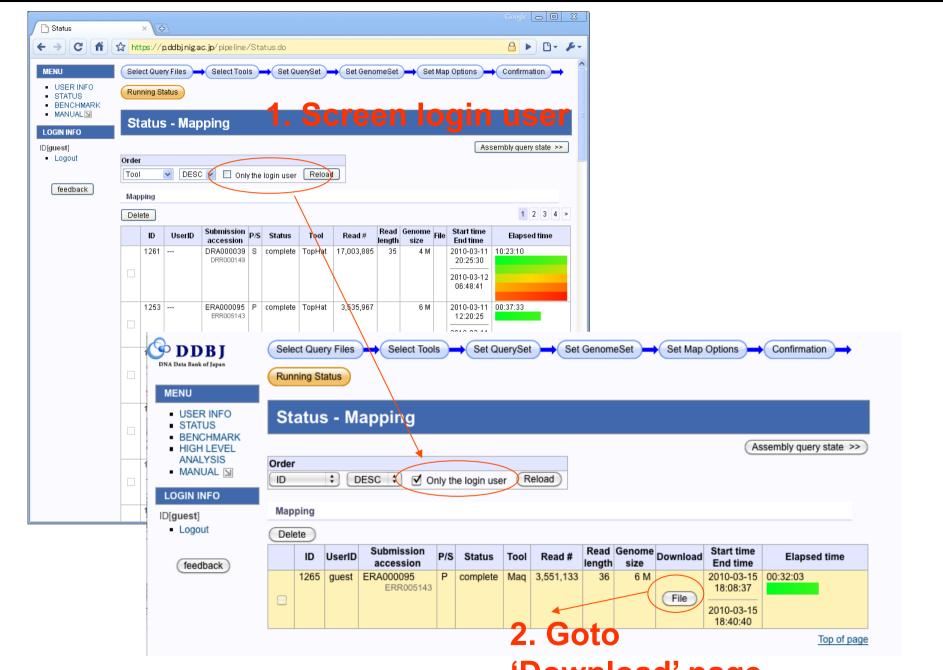


3. Go to next

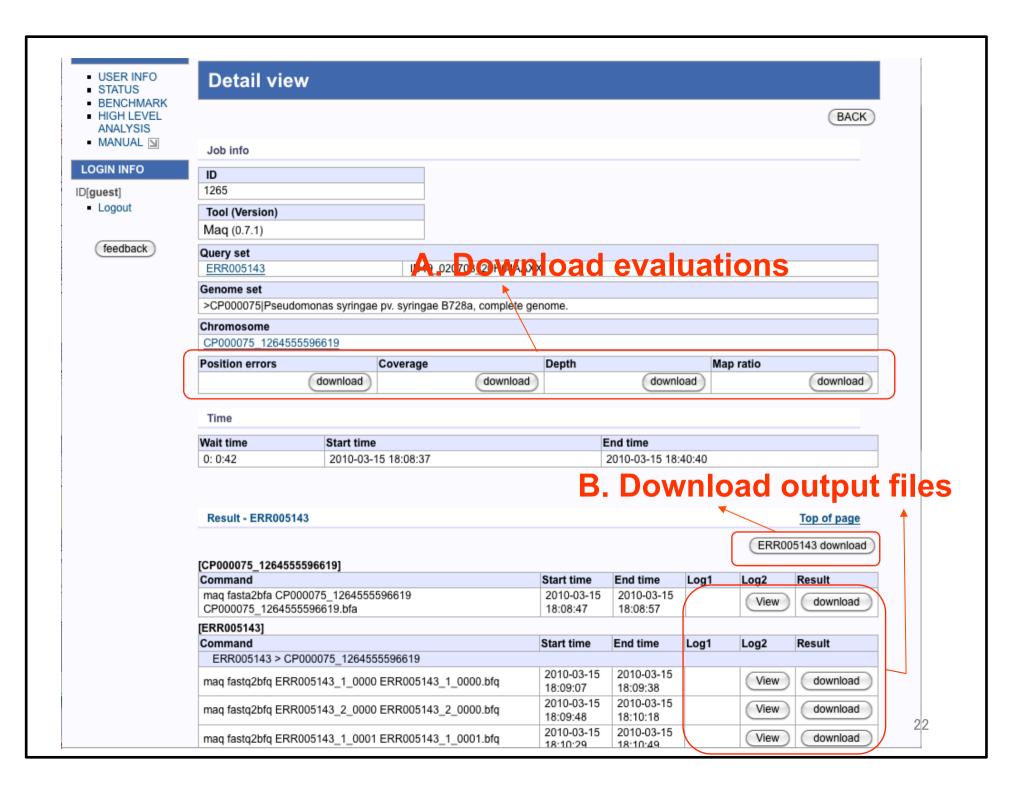
18







'Download' page

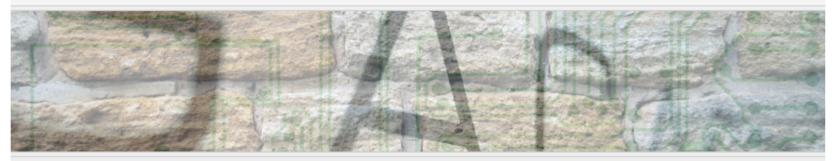




## Viewerを起動(Tablet)



#### http://bioinf.scri.ac.uk/tablet/



## 1. ローカルディレクトリにTabletをインストールPlant Bioinformatics Group

#### Tablet

- Tablet Homepage
- Download Tablet
- Screenshots
- Tablet FAO
- Sample Data
- Assembly Conversion
- Papers and Presentations
- Privacy Policy
- Tablet World Map
- Online Help

#### Our Software

- CurlyWhirly
- Flapjack
- OPTIRas
- Strudel
- Tablet (new)
- TetraploidMap

#### Tablet - Next Generation Sequence Assembly Visualization

Tablet is a lightweight, high-performance graphical viewer for next generation sequence assemblies and alignments.



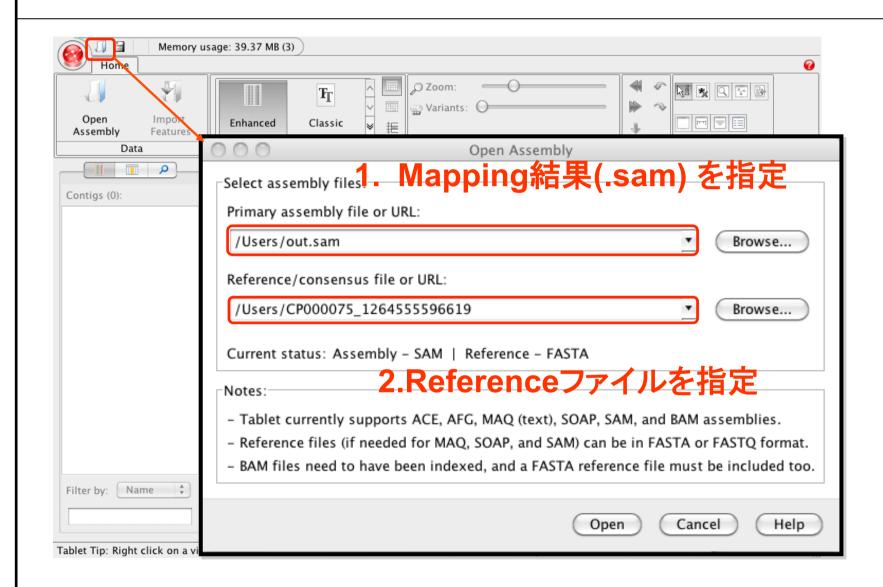


## Mapping結果をダウンロード

Detail view						1
				(	BACK	
Job info						
1. R	ofore	nce	<b>5</b>	PA	المراا	Mapping結果ファイル する。
1265						mapping #HX > / I/
Tool (Version)	com	1大人	<b>*</b>	1 × 7 E	<b>コ</b> ビ	<b>→</b> Z
Maq (0.7.1)	Sam	127	ァ・ノ		<b>-</b>  -	19 <b>0</b> 。
Query set						
ERR005143 ID49_020708_20H04AAX	X					
Genome set						
>CP000075 Pseudomonas syringae pv. syringae B728a, complete ge	enome.					
Chromosome						
CP000075_1264555596619						
						_
•						
	10.13.20	10.20.00				
gffConvert mapview.txt mapview.gff	2010-03-15	2010-03-15	View		download	
mag indelsoa CP000075 1264555596619.bfa out all.map >	18:20:29 2010-03-15	18:21:10 2010-03-15				
out.indel.soa	18:21:30	18:21:51			download	
maq assemble [-t 0.5 -r 0 -m 4] out.cns	2010-03-15	2010-03-15		View	download	
CP000075_1264555596619.bfa out_all.map	18:22:01	18:22:42		(1011)	Gommodd	
maq cns2snp out.cns > out.snp	2010-03-15 18:22:52	2010-03-15 18:23:02			download	
LONDS AD ADA AN	2010-03-15	2010-03-15			(damele ad	
maq.pl SNPfilter [-D 124 -w 4] out.snp > out.filter.snp	18:23:12	18:23:22			download	
maq2sam out_all.map > out.sam	2010-03-15	2010-03-15			download	
	18:23:33 2010-03-15	18:24:24 2010-03-15				
samtools view -bS -o headeredout.bam headeredout.sam	18:27:47	18:28:58		View	download	
samtools view -X headeredout.bam > out.samX	2010-03-15	2010-03-15			download	
Samuous view -A neaderedout.pam > out.samA	18-29-19	18:30:21			download	

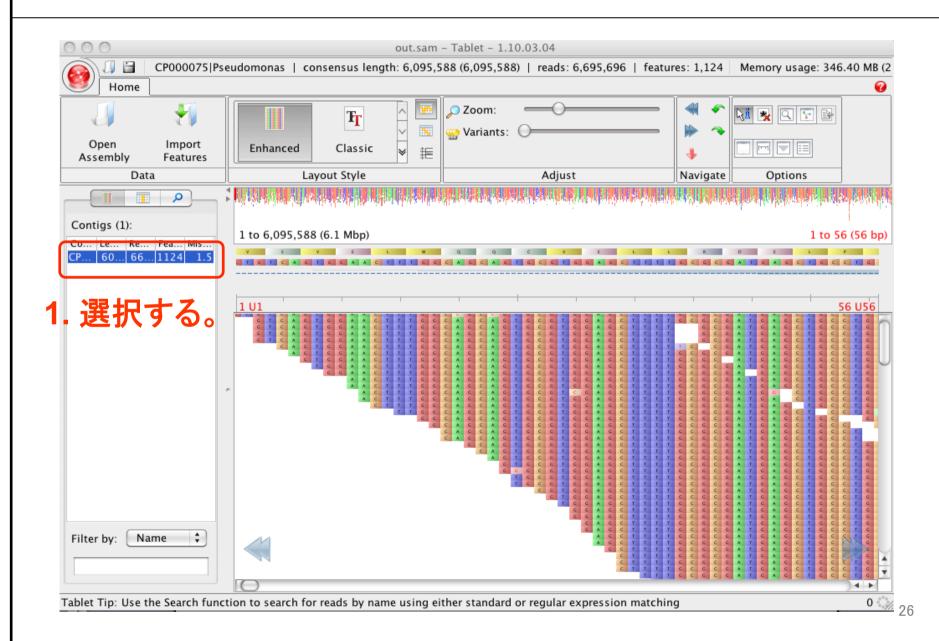


## 結果ファイルとreference配列を指定





## Mapping結果をviewerで表示



## Acknowledgements

- Jun Mashima
- Toshihisa Okido
- Asami Nozaki
- Hitoshi Kunii
- Daisuke Ikumi
- Takeshi Konno
- ·Nobuhiro Hoshi
- ·Shouta Morizaki
- Yoshio Tateno
- DDBJ Annotators, members

DRA is part of the National project of integrating life science databases, and is supported by the Japan Science and Technology Agency Institute for Bioinformatics Research and Development.